Target Engineering: cómo correr un peso

Instrucciones paso a paso para correr uno o varios pesos de BAJA+1 en una VM de Google Cloud

Qué se corre

El experimento entrena el mismo modelo que el baseline (Exp_0), con una sola diferencia: los BAJA+1 entran al entrenamiento con un peso *w* (BAJA+2 y CONTINUA tienen peso 1). Hay un script por peso. Cada uno corre la optimización bayesiana (22 evaluaciones), después entrena 10 semillas y predice 202106.

Peso de BAJA+1	Script	Carpeta de resultados
0.75	target_engineering/TE_w0.75.R	~/dmeyf/exp/TE_w0.75/
0.50	target_engineering/TE_w0.50.R	~/dmeyf/exp/TE_w0.50/
0.25	target_engineering/TE_w0.25.R	~/dmeyf/exp/TE_w0.25/
0 (solo BAJA+2)	target_engineering/TE_w0.00.R	~/dmeyf/exp/TE_w0.00/
1.50 (control)	target_engineering/TE_w1.50.R	~/dmeyf/exp/TE_w1.50/

El peso 1 es Exp_0 (el baseline) y no tiene script propio. Cada peso tarda **unas 34 horas**: ~15 h de BO y ~19 h de semillas.

En el resto del documento, donde dice `<peso>`, reemplazalo por el peso tal como aparece en el nombre del script: `0.75`, `0.50`, `0.25`, `0.00` o `1.50`. Por ejemplo, para el peso 0.25, `TE_w<peso>.R` es `TE_w0.25.R`.

> **Importante:** corré solo los pesos que acordamos que te tocan. Si un peso se corre dos veces no se rompe nada, pero se pierden ~34 h de VM.

Paso 1 — Preparar la VM (una sola vez por VM)

Usá una VM con la misma configuración que la de Exp_0 (misma cantidad de CPUs y memoria), así los tiempos son comparables y no falta RAM. Entrá por SSH y cloná el repositorio **exactamente en ~/dmeyf**, que es donde los scripts buscan todo:

```
git clone https://github.com/gromadzyn/dmeyf2026.git ~/dmeyf
mkdir -p ~/dmeyf/datasets ~/dmeyf/exp
```

Si ya tenés una carpeta ~/dmeyf de antes, renombrala primero (`mv ~/dmeyf ~/dmeyf_viejo`) o el clone va a fallar.

Paso 2 — Copiar el dataset

El dataset no está en el repositorio. Copiá el archivo **competencia_02_crudo.csv.gz** (el de la cátedra) a `~/dmeyf/datasets/`, sin descomprimirlo y sin cambiarle el nombre. Verificá que esté:

```
ls -lh ~/dmeyf/datasets/competencia_02_crudo.csv.gz
# tiene que aparecer el archivo, de unos 680 MB
```

Paso 3 — Verificar que la VM esté libre

LightGBM reparte cada árbol entre todos los núcleos y los hilos se esperan entre sí. Si **cualquier** otro proceso ocupa aunque sea un núcleo, la corrida no se enlentece un poco: **se puede trabar durante horas** mientras R sigue mostrando la CPU alta. Nos pasó con Exp_0: el escritorio remoto de GNOME quedó usando un núcleo al 100% y una semilla que tarda ~100 min no había terminado en 17 h.

Antes de lanzar, mirá qué está usando CPU:

```
top -bn1 | head -15
```

En la columna **%CPU** no tiene que haber nada cerca de 100 (salvo, después, tu propio R). Si aparece `gnome-r+` (el escritorio remoto de GNOME) y te conectás por SSH, desactivalo:

```
sudo systemctl stop gnome-remote-desktop
sudo systemctl disable gnome-remote-desktop   # para que no vuelva al reiniciar
```

Si es otro proceso que no necesitás, frenalo con `sudo kill <PID>` (el PID es la primera columna de `top`). Si no sabés qué es, preguntá antes de matarlo.

Paso 4 — Lanzar la corrida

Un solo peso. Este comando lo corre en segundo plano: podés cerrar la ventana de SSH y la corrida sigue.

```
cd ~/dmeyf && git pull
nohup Rscript target_engineering/TE_w<peso>.R > /dev/null 2>&1 &
```

Varios pesos en la misma VM. Se corren uno detrás del otro (cada uno ~34 h). Poné los scripts que te toquen separados por `;`. Ejemplo con dos pesos:

```
cd ~/dmeyf && git pull
nohup bash -c "Rscript target_engineering/TE_w<peso_1>.R; \
               Rscript target_engineering/TE_w<peso_2>.R" > /dev/null 2>&1 &
```

- La primera vez R instala los paquetes que faltan; puede tardar unos minutos.
- No lances dos pesos **al mismo tiempo** en la misma VM: LightGBM ya usa todos los núcleos y los dos se vuelven más lentos.
- Si tenés varias VMs, lo más rápido es un peso por VM, cada una con el comando de un solo peso. Cada VM necesita los pasos 1 y 2.

Paso 5 — Ver cómo va

Cada peso escribe su log en `~/dmeyf/exp/TE_w<peso>.log`. Para mirarlo en vivo (se sale con Ctrl+C; la corrida sigue):

```
tail -f ~/dmeyf/exp/TE_w<peso>.log
```

Qué querés saber	Comando	Qué esperar
¿Sigue corriendo?	`ps aux | grep [R]script`	Aparece un proceso Rscript con CPU alta. Si no aparece nada, terminó o se cortó.
¿En qué parte de la BO va?	`wc -l ~/dmeyf/exp/TE_w<peso>/bo_evaluaciones.txt`	Son 22 evaluaciones (~40 min cada una). El archivo llega a 23 líneas (22 + encabezado).
¿Cuántas semillas van?	`ls ~/dmeyf/exp/TE_w<peso>/semillas | wc -l`	Van de 0 a 10 (~100 min cada una). Con 10, ese peso terminó.
¿Cuándo terminó cada semilla?	`ls -l --time-style=+'%d/%m %H:%M' ~/dmeyf/exp/TE_w<peso>/semillas`	Una semilla nueva cada ~100 min. Si la última tiene **más de 3 h**, está trabada: ver paso 6.

Cuando un peso termina, al final de su log aparece un resumen que empieza con `==== TE_w<peso> ====`, con la ganancia y los envíos.

Paso 6 — Si la corrida se corta o se traba

Si la VM se reinicia, se apaga o el proceso muere, **volvé a lanzar el mismo comando del paso 4**. El script retoma solo: las evaluaciones de la BO y las semillas que ya estaban terminadas no se vuelven a calcular. En el log vas a ver mensajes como `BO: se retoman 14 evaluaciones` o `Semilla ... retomada de la corrida anterior`.

Si habías lanzado varios pesos juntos, volvé a lanzar el comando con todos: los que ya habían terminado se saltean en unos minutos (solo repiten la carga del dataset) y el que se cortó sigue desde donde estaba.

Si está trabada (pasaron más de 3 h sin semilla nueva, o más de 2 h sin evaluación nueva de la BO, aunque R muestre la CPU alta):

- Corré `top -bn1 | head -15` y buscá otro proceso usando CPU, como en el paso 3. Si hay uno, frenalo y esperá hasta 2 h: muchas veces la corrida se recupera sola.
- Si no se recupera, matá R y volvé a lanzar el comando del paso 4. Se pierde solo la semilla que estaba en curso:

```
pkill -f TE_w          # corta la cadena de pesos (si lanzaste varios)
pkill -f te_nucleo.R   # corta el entrenamiento en curso
ps aux | grep [R]script    # no tiene que aparecer nada
```

> **No borres** las carpetas `~/dmeyf/exp/TE_w...`: ahí están los checkpoints. Borrar una hace empezar ese peso de cero.

Paso 7 — Juntar los resultados

Cuando terminen tus pesos, empaquetá los resultados de esa VM:

```
cd ~/dmeyf/exp
tar czf resultados_TE.tar.gz TE_w*
ls -lh resultados_TE.tar.gz
```

`TE_w*` incluye las carpetas y los logs de todos los pesos que corriste en esa VM. Bajalo a tu computadora desde la ventana de SSH del navegador (engranaje arriba a la derecha, **Descargar archivo**, ruta `/home/<tu_usuario>/dmeyf/exp/resultados_TE.tar.gz`) y compartilo con el grupo. Para el análisis hacen falta los archivos `semillas/pred_*.txt` de cada peso, junto con los de Exp_0.

También se pueden compartir resultados parciales en cualquier momento: el análisis usa las semillas que ya estén terminadas.

Reglas para que la comparación sea válida

- **No modifiques el código** (ni `te_nucleo.R` ni los `TE_w*.R`). El experimento compara pesos *ceteris paribus*: si algo cambia en una sola corrida, deja de ser comparable.
- Si hace falta un cambio, se hace en el repositorio para todos los pesos y se avisa antes de correr.
- Hacé `git pull` antes de lanzar, no en medio de una corrida.

Problemas frecuentes

Lo que ves en el log	Qué significa y qué hacer
`File '.../competencia_02_crudo.csv.gz' does not exist`	El dataset no está en `~/dmeyf/datasets/` o tiene otro nombre. Revisá el paso 2.
Error instalando `lightgbm` u otro paquete	Instalalo a mano y volvé a lanzar: `Rscript -e 'install.packages("lightgbm", repos="https://cloud.r-project.org")'`
El log se corta de golpe, sin error	Suele ser falta de memoria. Verificá con `sudo dmesg | grep -i kill`; si aparece *Out of memory*, hace falta una VM con más RAM. Después se retoma como en el paso 6.
`bo_evaluaciones.txt no corresponde a esta configuracion`	La carpeta del experimento es de otra versión del código. No la borres: avisá al grupo antes de hacer nada.
No aparece una semilla nueva en más de 3 h, pero R usa mucha CPU	Hay otro proceso compitiendo por los núcleos y la corrida se trabó. Ver paso 6.
Cualquier otro error	Compartí con el grupo las últimas líneas del log: `tail -50 ~/dmeyf/exp/TE_w<peso>.log`